



APIs de IA Generativa e Prompt Engineering

Autoria: Erick Wendel Gomes da Silva

Indicações de leitura

Prezado aluno (a), selecionamos as referências abaixo visando o aprofundamento das temáticas estudadas na disciplina e a complementação dos seus estudos.

[Indicação 1: Ahmed, S. *Mastering Advanced RAG Techniques: A Comprehensive Guide*. Medium, 22 fev. 2025.](#)

Este artigo é uma ótima referência para quem já entende o básico de RAG e quer evoluir para uma arquitetura mais robusta em produção. O autor organiza o conteúdo de forma prática em etapas do pipeline — **indexação**, **pré-retrieval**, **retrieval** e **pós-retrieval** — cobrindo técnicas como **hierarchical indexing**, **compressão/quantização de vetores**, **query expansion**, **query decomposition**, **multi-hop retrieval**, **hybrid search**, **reranking com cross-encoders**, **fine-tuning de embeddings**, **remoção de outliers**, **context compression** e **document fusion**. Além disso, o texto reforça a importância de **validação contínua** e de começar por melhorias de alto impacto (como hybrid search e reranking), o que torna a leitura especialmente útil para times que querem melhorar relevância, reduzir ruído e otimizar custo/token em aplicações com LLMs

[Indicação 2: Swisskyrepo. *PayloadsAllTheThings — Prompt Injection*. GitHub \(repositório PayloadsAllTheThings\).](#)

Este material é uma ótima referência para quem quer **estudar prompt injection com foco em segurança** e entender melhor como aplicações com LLMs podem ser testadas e endurecidas. A página organiza o tema em tópicos como **system prompt**, **direct prompt injection** e **indirect prompt injection**, além de reunir exemplos, cenários de abuso, ferramentas, desafios e referências para aprofundamento. Também é útil porque mostra como ataques podem aparecer em diferentes superfícies (ex.: conteúdo externo, comentários, metadados e respostas de API), ajudando times técnicos a pensar em **sanitização de entrada**, **isolamento de contexto**, **validação de saída** e **testes de segurança** em pipelines com IA

[Indicação 3: LangChain Docs. *Evaluate Agent Performance / Test \(JavaScript/TypeScript\) + LangSmith Evaluation Quickstart*.](#)

Esse conjunto de guias é excelente para criar uma rotina de **testes e avaliação contínua**, que é uma das melhores práticas mais ignoradas em apps com IA. A documentação mostra como avaliar resultados/trajectories com LangSmith, e também traz caminhos práticos para integrar evals ao fluxo com **Vitest/Jest** ou via função **evaluate**, além de

explicar conceitos como dataset, target function e evaluators. É ideal para quem quer sair do “funciona no meu prompt” e entrar em qualidade mensurável.

